



DuocUC[®] INFORMÁTICA Y
TELECOMUNICACIONES



Optimizadores

- TLY1102

A black and white photograph of a man in a suit holding a tablet, standing in a modern office with glass partitions and a desk in the foreground. The image is overlaid with a blue square on the left and a grey rectangle on the right.


01

El Gradiente

• El Gradiente

Recordemos que, el descenso de gradiente es un algoritmo que **estima numéricamente dónde una función genera sus valores más bajos**.

Eso significa que encuentra mínimos locales.




• Desvanecimiento

El problema del desvanecimiento del gradiente surge durante el backpropagation, cuando **las derivadas o pendientes de las funciones de activación se vuelven progresivamente más pequeñas** a medida que nos movemos hacia atrás a través de las capas de una red neuronal.

Este fenómeno es particularmente prominente en redes profundas con muchas capas, lo que dificulta el entrenamiento efectivo del modelo.

Las actualizaciones de peso se vuelven extremadamente pequeñas, o incluso exponencialmente pequeñas, lo que puede prolongar significativamente el tiempo de entrenamiento y, en el peor de los casos, puede detener el proceso de entrenamiento por completo.




Fuente: <https://aiml.com/what-do-you-mean-by-vanishing-and-exploding-gradient-problem-and-how-are-they-typically-addressed/>

• Explosión

El problema de explosión del gradiente se presenta durante el entrenamiento de redes neuronales profundas.

Se produce cuando los gradientes de la función de pérdida de la red con respecto a los pesos (parámetros) **se vuelven excesivamente grandes**.

Esto dificulta la convergencia y potencialmente impide que la red neuronal aprenda y optimice eficazmente sus parámetros.




Fuente: <https://aiml.com/what-do-you-mean-by-vanishing-and-exploding-gradient-problem-and-how-are-they-typically-addressed/>

• Técnicas de solución

Combinados con otras estrategias (como usar distintas funciones de activación, inicializadores o Batch normalization, entre otros) **los optimizadores pueden ser muy efectivos.**

El **optimizador más básico posible** lo que hace es actualizar los valores de los parámetros, equitativamente, **con base al learning rate.**




Fuente: <https://www.baeldung.com/cs/learning-rate-batch-size>

• Optimizadores

Adam: Combina lo mejor de SGD con momentum y AdaGrad, ajustando dinámicamente las tasas de aprendizaje para cada parámetro. Es el más usado y robusto para la mayoría de los casos.

RMSProp: Adecuado para problemas no estacionarios, ajusta la tasa de aprendizaje según el promedio cuadrático de gradientes recientes.




Fuente: https://ml-lectures.org/docs/supervised_learning_w_NNs/NN-opt-reg.html

• Optimizadores

AdaGrad: Bueno para problemas con características esparsas (conjuntos de datos donde la mayoría de los valores en las características (columnas) son ceros o valores que no aportan información significativa), ya que acumula la historia de los gradientes.

SGD con Momentum: Mejora SGD tradicional al incorporar una memoria del gradiente pasado, ayudando a superar mínimos locales y mejorar la convergencia.

AdamW: Una variante de Adam que agrega regularización explícita (decaimiento de peso), ideal para evitar sobreajuste.



Fuente: https://ml-lectures.org/docs/supervised_learning_w_NNs/NN-opt-reg.html

DuocUC[®]



CERCANÍA. LIDERAZGO. FUTURO.

7
AÑOS
ACREDITADO



NIVEL DE EXCELENCIA
HASTA OCTUBRE 2031

Docencia de pregrado / Gestión institucional / Aseguramiento interno de la calidad / Vinculación con el Medio / Investigación, creación y/o innovación