



Evaluación Parcial N°1

Presentación y defensa técnica del proyecto | Docente

Evaluación Parcial N°1

Presentación

Estudiante

Sigla	Nombre Asignatura	Tiempo Asignado	% Ponderación	Semana inicio EFT
TLY1101	Técnicas Avanzadas de MACHINE LEARNING I	5 h	30%	

1.Tabla de especificaciones

Resultado de Aprendizaje	Indicador de Logro (IL)	Ponderación Indicador de Logro	Indicador de Evaluación (IE)	Ponderación Indicador de Evaluación	Situación Evaluativa (Encargo o Presentación)	Ítem (Indicar el ítem que contiene instrucciones de este IE)
RA1	IL1.1 Describe la estructura de una red neuronal profunda básica, identificando sus componentes y funciones, a partir de esquemas o implementaciones simples.	30%	IE1: Definición del problema y selección del dataset IE2: Preprocesamiento de datos.	30%	Presentación + defensa	
RA1	IL1.2 Implementa un perceptrón multicapa, configurando sus capas y funciones de activación, utilizando librerías de aprendizaje automático en problemas simples de clasificación o regresión sobre distintos tipos de datos.	35%	IE3: Implementación del modelo MLP IE4: Entrenamiento y validación.	35 %	Presentación + defensa	
RA1	IL1.3 Utiliza métricas de desempeño, interpretando resultados básicos del modelo, a partir de su implementación en tareas de predicción.	35%	IE5: Análisis de resultados y errores. IE6: Trazabilidad, documentación y presentación.	35%	Presentación + defensa	
		100%		100%		

2. Instrucciones generales

Descripción
En esta evaluación, cada grupo deberá implementar un modelo de red neuronal tipo MLP para resolver un problema de clasificación utilizando uno de los datasets propuestos. El objetivo no será solamente obtener una métrica alta, sino comprender el flujo completo de trabajo en aprendizaje supervisado: carga de datos, preprocesamiento, definición de clases, entrenamiento, validación y análisis de resultados. Para evitar la copia, cada grupo deberá definir una variante específica del problema. Esta variante puede considerar una selección distinta de clases, una cantidad limitada de imágenes por clase, una semilla propia para dividir los datos o una comparación entre subconjuntos del dataset. Por ejemplo, un grupo podría trabajar con cinco razas de mascotas, otro con clasificación binaria entre perros y gatos, otro con seis escenarios naturales o con un subconjunto de letras del lenguaje de señas. Qué deberán hacer los estudiantes • Describir el dataset seleccionado y justificar su elección. • Definir el problema de clasificación que resolverá. • Aplicar preprocesamiento básico a los datos. • Implementar una red MLP como modelo base. • Entrenar el modelo y reportar métricas de desempeño. • Analizar errores mediante ejemplos mal clasificados. • Explicar las limitaciones del uso de MLP en imágenes ▪ Durante el desarrollo del proyecto, los estudiantes deberán aplicar las distintas etapas del proceso de ciencia de datos, considerando la comprensión del problema, preparación de datos, análisis exploratorio y evaluar el impacto ético. ▪ El tiempo asignado para desarrollar esta evaluación en la sala de proyectos es de 5 horas y se realiza de manera grupal. ▪ Cada estudiante/equipo cuenta con 10 minutos para su presentación

- Si bien, esta evaluación es posible desarrollarla y rendirla de manera grupal, la presentación será evaluada de manera **Individual y estará asociada al desempeño de cada estudiante, ya sea mediante la calidad de su exposición, así como también en las respuestas a las preguntas realizadas por su docente. Por lo anterior, cada estudiante debe estar preparado para responder preguntas cruzadas, es decir, no necesariamente se le realizarán preguntas específicamente de lo que haya presentado individualmente.**

Se espera que los/as estudiantes desarrollen una solución de clasificación de imágenes mediante la implementación de un Perceptrón Multicapa (MLP), aplicando los fundamentos de las redes neuronales profundas revisados durante la primera experiencia de aprendizaje. La implementación deberá evidenciar un flujo de trabajo organizado que considere la selección y comprensión del conjunto de datos, el preprocesamiento de las imágenes, el diseño de la arquitectura del modelo, el entrenamiento, la evaluación del desempeño y el análisis crítico de los resultados, siguiendo las buenas prácticas de programación estudiadas durante la asignatura.

Esta implementación será evaluada principalmente mediante los Indicadores de Logro IL1.1 e IL1.2, los cuales establecen que el/la estudiante describe la estructura de una red neuronal profunda básica e implementa un perceptrón multicapa utilizando librerías especializadas de aprendizaje automático. En este contexto, se espera observar una adecuada comprensión de los componentes que conforman una red neuronal (capas, neuronas, pesos, funciones de activación y función de pérdida), así como la correcta configuración de la arquitectura del modelo, la selección de hiperparámetros básicos y la justificación técnica de las decisiones adoptadas durante su construcción.

Asimismo, la evaluación considerará la capacidad de los/as estudiantes para entrenar y validar el modelo mediante una metodología de experimentación básica, comparando distintas configuraciones cuando corresponda y analizando el efecto de decisiones como el número de capas ocultas, cantidad de neuronas, funciones de activación, número de épocas, tamaño del batch o tasa de aprendizaje. Estos aspectos serán valorados a través de los Indicadores de Evaluación asociados a los IL1.1 e IL1.2, considerando tanto la correcta implementación técnica del modelo como la capacidad para fundamentar las decisiones tomadas durante su desarrollo.

Por otra parte, se espera que los/as estudiantes evalúen el desempeño del modelo utilizando métricas apropiadas para problemas de clasificación, tales como Accuracy, Precision, Recall, F1-Score y Matriz de Confusión, complementando este análisis con la interpretación de las curvas de entrenamiento y validación, así como el estudio de ejemplos correctamente e incorrectamente clasificados. Además, deberán identificar las principales limitaciones del modelo MLP cuando se utiliza para clasificación de imágenes, proponiendo posibles mejoras que podrán ser abordadas en las siguientes experiencias de aprendizaje mediante arquitecturas más especializadas.

Estos elementos serán evaluados mediante el Indicador de Logro IL1.3, el cual establece que el/la estudiante utiliza métricas de desempeño para interpretar los resultados obtenidos por un modelo de aprendizaje profundo en tareas de predicción. En consecuencia, no solo se evaluará la correcta implementación y cálculo de las métricas, sino también la capacidad para interpretar críticamente los resultados, identificar

fortalezas y debilidades del modelo, justificar técnicamente las decisiones adoptadas durante su construcción y proponer mejoras fundamentadas para futuras iteraciones del proyecto.

SET DE DATOS

1. Oxford-IIIT Pet Dataset

Problema: Clasificación de razas de perros y gatos.

Características

- 7.349 imágenes
- 37 clases
- Variabilidad de iluminación, postura y fondo
- Excelente para experimentar con overfitting
- <https://www.kaggle.com/datasets/tanlikesmath/the-oxfordiiit-pet-dataset>

2. Intel Image Classification Dataset

Problema: Clasificación de escenarios naturales.

Características

- ~25.000 imágenes
- 150×150 px
- 6 clases
- <https://www.kaggle.com/datasets/puneet6060/intel-image-classification>

3. Los Simpson Dataset

Problema: Reconocer letras del lenguaje de señas.

Características

- Imágenes RGB (3 canales).
- Resolución variable (redimensionadas durante el preprocesamiento según la arquitectura utilizada).
- 42 clases.
- Aproximadamente 20.000.

- <https://www.kaggle.com/datasets/alfaro96/los-simpson/data>

4. PlantVillage Dataset

Problema: Detección de enfermedades agrícolas.

Características

- Más de 54.000 imágenes
- 38 clases
- Diferentes especies vegetales
- <https://www.kaggle.com/datasets/emmarex/plantdisease>

Instrucciones específicas de la Evaluación:

La presentación debe incluir los siguientes **apartados**:

- Descripción del problema de negocio, definición de KPIs y objetivos del proyecto.
- Análisis exploratorio de los datos (EDA), incluyendo identificación de patrones, calidad de datos y variables relevantes.
- Preparación y transformación de datos para el proceso de modelamiento.

Modalidad de la evaluación: Presentación de evidencias y defensa técnica del proyecto de Machine Learning.

Los aspectos formales son:

Los materiales, herramientas o insumos requeridos para realizar esta evaluación corresponden a un informe técnico en formato Markdown, el cual deberá documentar de manera estructurada todo el desarrollo del proyecto de Machine Learning.

Los estudiantes deberán entregar:

- **Informe técnico en formato Markdown (.md)**, elaborado como un documento reproducible similar a un README de un proyecto de Machine Learning, que incluya como mínimo las siguientes secciones:
 - Descripción del problema de negocio.
 - Objetivos del proyecto.
 - Definición de KPIs que resolverán el problema de negocio.
 - Descripción de las fuentes de datos utilizadas.
 - Preparación y análisis exploratorio de los datos (EDA).
 - Metodología utilizada (CRISP-DM).
- Notebook en Python (.ipynb) debidamente documentado, organizado y completamente ejecutable, que permita reproducir cada una de las etapas desarrolladas en el informe.
- Conjunto de datos y archivos complementarios utilizados durante el desarrollo del proyecto, organizados de manera que permitan ejecutar nuevamente la solución sin modificaciones adicionales.
- Carpeta del proyecto organizada siguiendo una estructura profesional (por ejemplo: data/, notebooks/, models/, images/ y README.md), de forma que cualquier usuario pueda comprender, ejecutar y reproducir la solución desarrollada.

Estructura sugerida del notebook

- a. Introducción: Presentar el problema de clasificación que será abordado, describiendo brevemente el contexto del conjunto de datos seleccionado y la variante definida para el proyecto. Además, explicar el objetivo del modelo que se desarrollará y las razones que justifican la elección del dataset.
- b. Comprensión y exploración del conjunto de datos: Describir las principales características del conjunto de datos seleccionado, indicando la cantidad de imágenes, número de clases, distribución de ejemplos y cualquier aspecto relevante para comprender el problema. Se espera incorporar visualizaciones representativas del dataset, explorando ejemplos de distintas clases y analizando posibles dificultades que podrían afectar el proceso de clasificación.
- c. Preparación y preprocesamiento de los datos: Implementar todas las etapas necesarias para preparar el conjunto de datos antes del entrenamiento del modelo.
- d. Diseño del Perceptrón Multicapa: Implementar una arquitectura MLP adecuada para resolver el problema propuesto. La descripción deberá incluir, al menos: número de capas ocultas; cantidad de neuronas por capa; funciones de activación utilizadas; función de salida; función de pérdida; optimizador seleccionado; hiperparámetros principales (épocas, batch size, learning rate u otros). Cada decisión deberá fundamentarse en relación con las características del problema y no únicamente por reproducir ejemplos existentes.
- e. Entrenamiento del modelo: Entrenar el modelo registrando el comportamiento del proceso de aprendizaje. Durante esta etapa se espera analizar: evolución de la función de pérdida; evolución de la precisión durante entrenamiento y validación; comportamiento del proceso

de convergencia; posibles signos de sobreajuste o bajo aprendizaje cuando existan. Las curvas obtenidas deberán incorporarse al notebook y ser interpretadas.

- f. Evaluación del desempeño: Evaluar el modelo utilizando múltiples métricas de clasificación. Como mínimo deberán reportarse: Accuracy; Precision; Recall; F1-Score; Matriz de Confusión. No basta con calcular estas métricas; también deberán interpretarse en función del problema estudiado, explicando qué información aporta cada una respecto del comportamiento del modelo.
- g. Análisis de resultados y errores: Realizar una auditoría básica del modelo analizando tanto sus aciertos como sus errores. Para ello se espera: seleccionar ejemplos correctamente clasificados; seleccionar ejemplos incorrectamente clasificados; explicar posibles causas de las predicciones erróneas; identificar las clases que presentan mayor nivel de confusión; discutir las principales limitaciones del uso de un Perceptrón Multicapa para resolver problemas de clasificación de imágenes. Este análisis deberá sustentarse mediante figuras, tablas y resultados experimentales.
- h. Conclusiones: Reflexionar sobre el trabajo realizado considerando: desempeño alcanzado por el modelo; principales decisiones de diseño adoptadas; fortalezas y limitaciones observadas; posibles mejoras que podrían implementarse en futuras versiones del modelo.

1. Pauta de Evaluación (Rúbrica, Escala de valoración, Pauta de cotejo)

Categoría	% logro	Descripción niveles de logro
Muy buen desempeño	100%	Demuestra un desempeño destacado, evidenciando el logro de todos los aspectos evaluados en el indicador.
Buen desempeño	80%	Demuestra un alto desempeño del indicador, presentando pequeñas omisiones, dificultades y/o errores.
Desempeño aceptable	60%	Demuestra un desempeño competente, evidenciando el logro de los elementos básicos del indicador, pero con omisiones, dificultades o errores.
Desempeño incipiente	30%	Presenta importantes omisiones, dificultades o errores en el desempeño, que no permiten evidenciar los elementos básicos del logro del indicador, por lo que no puede ser considerado competente.
Desempeño no logrado	0%	Presenta ausencia o incorrecto desempeño.

Indicador de Evaluación	Categorías de Respuesta					Ponderación Indicador de Evaluación
	Muy buen desempeño 100%	Buen desempeño 80%	Desempeño aceptable 60%	Desempeño incipiente 30%	Desempeño no logrado 0%	
1. Definición del problema y selección del dataset	Define claramente el problema, justifica el dataset y establece una variante propia del trabajo.	Define el problema y el dataset de forma adecuada, con una justificación general.	Define parcialmente el problema o justifica de forma limitada la selección del dataset.	Presenta una definición poco clara y una justificación insuficiente del dataset.	No define el problema ni justifica la selección del dataset.	15%
2.- Preprocesamiento de datos	Aplica correctamente la carga, transformación, normalización y preparación de los datos para el entrenamiento del MLP, justificando cada etapa.	Aplica un preprocesamiento funcional con pequeñas omisiones en la documentación o justificación.	Aplica un preprocesamiento básico, con errores u omisiones que afectan parcialmente el desarrollo.	Presenta un preprocesamiento incompleto o con errores importantes.	No prepara correctamente los datos para el entrenamiento.	15%
3.- Implementación del modelo MLP	Implementa una arquitectura MLP funcional y coherente con el problema, justificando capas, funciones de activación e hiperparámetros.	Implementa una MLP funcional con una justificación parcial de la arquitectura.	Implementa una MLP básica con decisiones parcialmente adecuadas.	Implementa un modelo incompleto o con errores relevantes en su arquitectura.	No implementa un modelo MLP funcional.	20%
4.- Entrenamiento y validación	Entrena y valida correctamente el modelo, registrando y analizando las métricas de entrenamiento y validación.	Entrena y valida el modelo correctamente, aunque el análisis es parcial.	Entrena el modelo, pero la validación o el análisis presentan debilidades.	Presenta un proceso de entrenamiento incompleto o poco confiable.	No evidencia un proceso válido de entrenamiento y validación.	15%
5.- Análisis de resultados y errores	Analiza métricas, matriz de confusión y ejemplos mal clasificados, identificando fortalezas y limitaciones del modelo.	Presenta las métricas y analiza los resultados con observaciones pertinentes.	Presenta resultados básicos con escasa interpretación técnica.	Reporta resultados con análisis superficial o poco fundamentado.	No analiza los resultados obtenidos.	20%

6.-Trazabilidad, documentación y presentación	Documenta completamente el proceso, incluyendo decisiones, partición de datos, semilla y justificación técnica; demuestra dominio durante la presentación.	Documenta la mayor parte del proceso y responde adecuadamente durante la presentación.	Presenta documentación suficiente, aunque con omisiones relevantes o una defensa limitada.	La documentación es incompleta y la presentación evidencia escaso dominio del trabajo.	No documenta el proceso ni demuestra comprensión del desarrollo realizado.	15%
					Total	100%