



DuocUC[®] INFORMÁTICA Y
TELECOMUNICACIONES



El Perceptrón


TLY1102

A black and white photograph of a man in a suit standing in a modern office, holding a tablet and smiling. The office has glass partitions and modern furniture. A blue square is visible in the upper right area of the image.



01

Introducción

• Hitos en el campo de la IA




• Machine Learning vs Deep Learning




Fuente: <https://towardsdatascience.com/artificial-intelligence-vs-machine-learning-vs-deep-learning-2210ba8cc4ac>

• Deep Learning

Representation learning (Deep learning) construye las presentaciones de los “inputs” por etapas, “en general” en cada proceso de abstracción con menos información



• Deep Learning



Fuente: DCC – UdeChile

<https://towardsdatascience.com/deep-learning-vs-classical-machine-learning-9a42c6d48aa>


A black and white photograph of a man and a woman in a modern office setting. The man, on the left, is wearing a light-colored button-down shirt and dark trousers. The woman, on the right, is wearing a dark blazer over a light-colored turtleneck. They are both looking at a tablet held by the man. In the background, there are office desks, computer monitors, and a person sitting at a desk. The overall atmosphere is professional and collaborative.

02

El Perceptrón

La idea de perceptrón como unidad de procesamiento en el Deep Learning toma como inspiración nuestra unidad de procesamiento lógico en el cerebro. **La neurona.**

Se construye entonces un mapeo entre los elementos biológicos y los computacionales. Acá la acción de la neurona y la comunicación entre ellas es reemplazada por la idea de producto y suma




Fuente: Biological neuron (public image freely licensed under Wikimedia Commons)

Una red neuronal biológica (como la que tenemos en nuestro cerebro) está compuesta por una gran cantidad de células nerviosas llamadas neuronas.

Cada neurona recibe señales eléctricas (impulsos) de sus neuronas vecinas a través de fibras llamadas dendritas.


Cuando la suma total de sus señales entrantes supera un cierto umbral, la neurona “dispara” su propia señal a través de fibras largas llamadas axones que están conectadas a las dendritas de otras neuronas.



Fuente: Biological neuron (public image freely licensed under Wikimedia Commons)

La unión entre dos neuronas se llama sinapsis. En promedio, cada neurona está conectada a unas 7.000 sinapsis, lo que demuestra la alta conectividad de la red que tenemos en nuestro cerebro.


Cuando aprendemos nuevas asociaciones entre dos conceptos, la fuerza sináptica entre las neuronas que representan estos conceptos se fortalece. Este fenómeno se conoce como la regla de Hebb (1949) que establece que “las células que se activan juntas se conectan entre sí”.



Fuente: <https://sistemanervioso.weebly.com/sinapsis.html>

El modelo del perceptrón, introducido por Frank Rosenblatt en 1957, es un modelo simplificado de una neurona biológica.

El perceptrón tiene m entradas binarias denotadas por $x_1, \dots, x_m$, que representan las señales entrantes de sus neuronas vecinas, y genera un único valor binario (out) que indica si el perceptrón está “activado” o no.



Fuente: <https://pythoniseasytolearn.blogspot.com/2020/09/perceptron-mother-of-all-anns.html>

Matemáticamente, el perceptrón es una función que recibe valores (x, w, b) y entrega un resultado $(\hat{y})$, (cuadro azul).

La operación que realiza esta función es la suma ponderada de los datos ingresados (cuadro café).

A este resultado, que representamos con la letra “u”, se le aplica una función, llamada función de activación .

Los “pesos” expresan la importancia de una entrada dada para generar una salida.


x_i : entradas (input)

w_i : pesos

b : bias (sesgo)

$\forall b, w_i \in \mathbb{R}$

$0 \leq x_i \leq 1$



$$u = x_1 w_1 + x_2 w_2 + x_3 w_3 + b$$



$$\hat{y} = f(u)$$

Función de activación

Los valores “w” y “b” reciben el nombre de parámetros.

A black and white photograph of a woman in a server room. She is standing in a narrow aisle between rows of server racks. She is holding a tablet in her left hand and touching a control panel on the side of a server rack with her right hand. The server racks are filled with equipment, and some fans are visible. The room is dimly lit, with bright lights on the ceiling.

03

Función de Activación

Función de Activación


La función de activación, **intenta emular lo que ocurre con las neuronas**, es decir, llegado cierto nivel de acumulación de estimulación, la neurona lanza la información a la neurona siguiente.

Es importante saber que siempre en las “funciones de activación” **se deben utilizar funciones no lineales**.

Originalmente, en los primeros intentos, se utilizaba la **función escalón**, donde, si el valor de “u” **es menor a cero**, la función **entrega un 0**, mientras que, si “u” **es mayor a 0**, el resultado de la función es 1.

Sin embargo, esta función, no es posible utilizarla en un entrenamiento del perceptrón, porque para entrenarlo, necesitamos derivar y la **derivada de esta función es 0 en cualquier punto**.

Función escalón (step)



Función de Activación


La función de activación que resuelve el problema anterior es la **función Sigmoide**.

Se usó durante mucho tiempo porque emulaba muy bien la neurona biológica y además es posible derivarla.

El problema que tiene esta función de activación es que **se satura a medida que los valores se alejan del eje “y”**.

Esto en términos prácticos producirá que la pendiente (en jerga de Deep learning se usa la palabra “gradiente”) sea muy baja para esos valores y la red **“no aprenda”**.

Función Sigmoide logística




Función de Activación

Hay otra función, llamada **Tanh**, que se aleja de la motivación biológica, pero que **funciona mucho mejor en la práctica que la anterior**. Debido a su derivada.

Sin embargo, acá ocurre lo mismo que pasa con la sigmoide, **en los extremos el gradiente (pendiente) es muy baja y la red “no aprenderá” y además podría alargar el entrenamiento de la red.**

Función Tanh



Función de Activación


Pero la función de activación que provocó una revolución en este concepto **es ReLu** (Rectified Linear Unit).

Generó un salto sustancial en el resultado de una red neuronal artificial. Es una de las innovaciones más importantes en las últimas décadas.

Si los valores de entrada son negativos es cero y luego los números positivos es la identidad del número de entrada.

Esto produce que **el gradiente (pendiente) no desaparezca.**

Función ReLu



NOTA: Lejos de aprender las fórmulas, lo importante es comprender los rangos en que se mueve y la forma que tiene la curva para poder estimar los efectos que potencialmente se producen en la red.

04

Multi Perceptrón



• Perceptrón de una capa


El perceptrón único en Deep learning solo permite aprender funciones linealmente separables.

La red neuronal multi perceptrón, nos permitirán **resolver problemas más complejos**.

La estructura de toda red neuronal cuenta de **una capa de entrada**, que realmente no es una capa como tal, pero que representa los datos de entrada.

La segunda componente es o son **las capas escondidas**, en este ejemplo estamos usando una sola capa.

Estructura de un Perceptrón de 1 capa (escondida)




• Perceptrón de una capa

Nótese que **cuando la red neuronal tiene más de una capa escondida, aparece la definición de redes neuronales profundas**, entre más capas tiene, más profunda se dice que es.

No hay un buen número para la cantidad de capas a crear. Todo depende de los datos, del problema que se quiera resolver.

Finalmente, viene **la capa de salida**, la cual puede ser un vector o un escalar y **representa una probabilidad cuando se está realizando una clasificación o un escalar cuando es una regresión** (predicción).

Estructura de un Perceptrón de 1 capa (escondida)




• Perceptrón de una capa

Nótese que verán en la práctica que **en la capa de salida también se aplica una función**, generalmente es softmax cuando se está realizando clasificación.

Pero, es importante **no confundir la función de activación con función de salida**, incluso una función identidad o sigmoid que nunca se debe utilizar como función de activación, si se puede utilizar como función en la capa de salida.

De hecho, eso ocurre en la realidad. Pero son conceptos e impactos diferentes.

Estructura de un Perceptrón de 1 capa (escondida)



• Perceptrón de una capa


Definiciones y conceptos

Todas las entradas (x), están conectadas con todas neuronas (p) (perceptrones) de la primera capa escondida.

Todas las entradas **reciben un peso (w)**, estos pesos son inicializados al azar siguiendo ciertas metodologías (x_1 con w_1 , x_2 con w_2 , x_i con w_i).

Cada perceptrón (p) tiene también **su propio bias (b)**, que también son inicializados al azar.

Estructura de un Perceptrón de 1 capa (escondida)



• Perceptrón de una capa


Definiciones y conceptos

Todos los perceptrones de la misma capa escondida **usan la misma función de activación**. Como lo dijimos anteriormente, en la práctica, esta función es ReLu (la más usada).

La **última neurona**, utiliza una **función de salida** “g” (no confundir con el concepto de función de activación) y también recibe su propio bias “c” generando un resultado $\hat{y}$.

P son las salidas de la capa escondida, que a su vez son las entradas de la capa de salida.

Estructura de un Perceptrón de 1 capa (escondida)



DuocUC[®]



CERCANÍA. LIDERAZGO. FUTURO.

7
AÑOS
ACREDITADO



NIVEL DE EXCELENCIA

HASTA OCTUBRE 2031

Docencia de pregrado / Gestión institucional / Aseguramiento interno de la calidad / Vinculación con el Medio / Investigación, creación y/o innovación